



Universidade Estadual de Campinas
Faculdade de Engenharia Agrícola



Caio Simplicio Arantes

RAVI: Complemento QGIS para Análise de Imagens de Satélite Sentinel-2

Campinas
2025



Universidade Estadual de Campinas
Faculdade de Engenharia Agrícola



Caio Simplicio Arantes

RAVI: Complemento QGIS para Análise de Imagens de Satélite Sentinel-2

Trabalho de Conclusão de Curso
apresentado como requisito parcial para
obtenção do título de **Engenheiro
Agrícola** à Faculdade de Engenharia
Agrícola da Universidade Estadual de
Campinas.

Orientador: Prof. Dr. Lucas Rios do Amaral
Coorientadora: Me. Isabella Alves da Cunha

Campinas
2025

Ficha catalográfica
Universidade Estadual de Campinas (UNICAMP)
Biblioteca da Área de Engenharia e Arquitetura
Rose Meire da Silva - CRB 8/5974

Ar14r Arantes, Caio Simplicio, 1995-
RAVI : complemento QGIS para análise de imagens de satélite Sentinel-2 /
Caio Simplicio Arantes. – Campinas, SP : [s.n.], 2025.

Orientador: Lucas Rios do Amaral.

Coorientador: Isabella Alves da Cunha.

Trabalho de Conclusão de Curso (Graduação) – Universidade Estadual de
Campinas (UNICAMP), Faculdade de Engenharia Agrícola.

1. Índices de vegetação. 2. Agricultura de precisão. 3. Sensoriamento
remoto. 4. Sistemas de informações geográficas. 5. Agricultura -
Sensoriamento remoto. I. Amaral, Lucas Rios do, 1985-. II. Cunha, Isabella
Alves da, 1999-. III. Universidade Estadual de Campinas (UNICAMP).
Faculdade de Engenharia Agrícola. IV. Título.

Informações complementares

Título em outro idioma: RAVI : QGIS plugin for sentinel-2 satellite image analysis

Palavras-chave em inglês:

Vegetation indices

Precision agriculture

Remote sensing

Geographic information system

Agriculture - Remote sensing

Titulação: Bacharel

Banca examinadora:

Lucas Rios do Amaral [Orientador]

Júlio César Dalla Mora Esquerdo

Gustavo Henrique Soares Ferreira

Data de entrega do trabalho definitivo: 18-12-2025

Objetivos de Desenvolvimento Sustentável (ODS)

ODS: 2. Fome zero e agricultura sustentável



RAVI: Complemento QGIS para Análise de Imagens de Satélite Sentinel-2

Caio Simplicio Arantes

BANCA EXAMINADORA

.....
Prof. Dr. Lucas Rios do Amaral
Orientador

.....
Dr. Júlio César Dalla Mora Esquerdo

.....
Me. Gustavo Henrique Soares Ferreira



DEDICATÓRIA

Aos meus pais,
Iracema Simplicio Arantes e
Ideraldo Oliveira Arantes (*in memoriam*),
cujo apoio incondicional foi fundamental



AGRADECIMENTOS

Agradeço ao Prof. Dr. Lucas Rios do Amaral por aceitar e orientar este trabalho (e pela paciência para tal); à coorientadora Me. Isabella Alves da Cunha pela dedicação nas correções; e a todos os membros do Grupo Interdisciplinar de Tecnologia em Agricultura de Precisão (GiTAP), em especial à Bruna da Silva Brito Ribeiro, que acompanharam e apoiaram este trabalho.

RESUMO

Diante do esforço despendido para acessar e processar imagens de Sensoriamento Remoto (SR) da constelação *Sentinel-2* por meio da plataforma *Copernicus Browser* ou a falta de habilidades em linguagens de programação para utilizar plataformas de computação em nuvem, como o *Code Editor* do *Google Earth Engine* (GEE), constitui uma limitação à adoção desses dados no monitoramento agrícola e ambiental. Para lidar com esse desafio, foi desenvolvido o RAVI (*Remote Analysis of Vegetation Indices*), um complemento para a plataforma QGIS que utiliza recursos de computação em nuvem do GEE e oferece uma interface gráfica de fácil utilização, abrangendo a seleção da área de interesse, o intervalo temporal de coleta, configurações de filtragem e aplicação de máscara de nuvem, bem como opções de visualização e exportação dos resultados de perfil temporal de Índice de Vegetação (IV). O objetivo deste trabalho foi apresentar e validar as ferramentas e funcionalidades do complemento para uso adequado no âmbito do sensoriamento remoto agrícola. O complemento foi validado por meio de um estudo de caso aplicado em uma área de produção comercial agrícola. Os resultados demonstraram que o complemento é uma ferramenta viável para as funcionalidades implementadas, como visualização do perfil temporal de índices de vegetação selecionados para a área de interesse, a criação de imagens sintéticas, o download e visualização de imagem multiespectral, assim como seus respectivos IVs em data selecionada. Embora seja necessário cadastro do usuário no GEE, a utilização do RAVI elimina a necessidade de aprender linguagem de programação e utilizar o *Code Editor* no escopo das funcionalidades oferecidas, otimizando o tempo de aquisição e processamento de imagens *Sentinel-2*. Assim, torna-se uma ferramenta apta para a obtenção de dados de áreas agrícolas, auxiliando no manejo e na pesquisa agrícola.

Palavras-chave: Índices de vegetação, agricultura de precisão, sensoriamento remoto, sistema de informações geográfica.

ABSTRACT

The considerable effort required to access and process satellite remote sensing images from the Sentinel-2 constellation via the Copernicus Browser platform, combined with the lack of programming skills needed to utilize cloud computing platforms like the Google Earth Engine (GEE) Code Editor, often hinders the adoption of these data for agricultural and environmental monitoring. To address this challenge, Remote Analysis of Vegetation Indices (RAVI) was developed. This QGIS plugin leverages GEE cloud computing capabilities and offers a user-friendly graphical interface, facilitating area of interest selection, time range definition, filtering settings, and cloud masking, as well as options for visualizing and exporting Vegetation Index (VI) time series results. The objective of this study was to present and validate the plugin's tools and functionalities for their effective application in agricultural remote sensing. The plugin was validated through a case study conducted in a commercial agricultural production area. Results demonstrated that the plugin is a viable tool for the implemented features, such as visualizing temporal profiles of selected vegetation indices for the area of interest, generating synthetic images, and downloading and visualizing multispectral images and their respective VIs for specific dates. Although GEE user registration is required, using RAVI eliminates the need to learn a programming language or use the Code Editor within the scope of the offered functionalities, thereby optimizing the acquisition and processing time of Sentinel-2 images. Thus, it proves to be a suitable tool for acquiring data on agricultural areas, assisting in both crop management and agricultural research.

Keywords: Vegetation indices, precision agriculture, remote sensing, geographic information system.

SUMÁRIO

1 INTRODUÇÃO	9
1.1 OBJETIVO	12
2 REVISÃO DE LITERATURA	13
2.1 AGRICULTURA DE PRECISÃO (AP)	13
2.2 SENSORIAMENTO REMOTO NA AGRICULTURA	14
2.2.1 Constelação Sentinel-2	15
2.2.2 Índices Espectrais e de Vegetação	17
2.2.3 Perfil de Série Temporal	18
2.2.4 Imagem Sintética	19
2.3 PLATAFORMAS COMPUTACIONAIS E PROCESSAMENTO EM NUVEM	20
3 DESENVOLVIMENTO DO COMPLEMENTO	22
3.1 LEVANTAMENTO DE REQUISITOS	22
3.2 BASE DE CÓDIGO	24
3.3 ENTRADA DE DADOS E CONFIGURAÇÕES	27
3.3.1 Autenticação (Passo 1)	27
3.3.2 Pasta de Saída (Passo 2)	28
3.3.3 Seleção da Área de Interesse (Passo 3)	28
3.3.4 Seleção do Intervalo de Tempo (Passo 4)	29
3.3.5 Seleção do Índice de Vegetação (Passo 5)	30
3.3.6 Filtro de Sobreposição de Imagens (Passo 6)	32
3.3.7 Opções de Buffer (Passo 7)	32
3.3.8 Filtro de Nuvem na Cena (Passo 8)	33
3.3.9 Filtro de Classificação de Cena (Passo 9)	33
3.3.10 Filtro de Imagem Única	34
3.3.11 Visão Geral	34
3.4 FUNCIONALIDADES ACESSÍVEIS NA ABA PAINEL	35
3.4.1 Perfil Temporal de IV (Painel A)	36
3.4.2 Visualização e Download de Imagens em Data Específica (Painel B)	38
3.4.3 Opções de Imagem Sintética (Painel C)	38
3.4.4 Opções de Remoção de Datas (Painel D)	38
3.4.5 Opções de Filtro Savitzky-Golay (Painel E)	38
3.4.6 Opções de dados NASA POWER (Painel F)	39

3.4.7 Opções para exportar dados tabulares (Painel G)	39
3.4.8 Opções para Alternar IV e Focar em Área (Painel H)	40
3.5 ANÁLISE MULTIFEIÇÃO E ANÁLISE DE PONTOS.....	40
4 ESTUDO DE CASO	42
4.1 CARACTERIZAÇÃO DA ÁREA DE ESTUDO	42
4.2 APLICAÇÃO PRÁTICA 1: MONITORAMENTO OPERACIONAL	43
4.3 APLICAÇÃO PRÁTICA 2: ANÁLISE RETROSPECTIVA E COMPARATIVA.....	43
4.4 APLICAÇÃO PRÁTICA 3: EXTRAÇÃO DE DADOS PARA ANÁLISES EXTERNAS	44
5 RESULTADOS E DISCUSSÃO	45
5.1 USABILIDADE E INTEGRAÇÃO COM O GEE	45
5.2 APLICAÇÃO PRÁTICA 1: MONITORAMENTO OPERACIONAL	46
5.3 APLICAÇÃO PRÁTICA 2: ANÁLISE RETROSPECTIVA E COMPARATIVA.....	49
5.4 APLICAÇÃO PRÁTICA 3: EXTRAÇÃO DE DADOS PARA ANÁLISES EXTERNAS	52
6 CONSIDERAÇÕES FINAIS	56
REFERÊNCIAS.....	57

1 INTRODUÇÃO

O Sensoriamento Remoto (SR) tem por objetivo obter informações sobre alvos a partir de sensores embarcados em plataformas terrestres, suborbitais e orbitais, e desempenha papel relevante na aplicação de Agricultura de Precisão (AP) ao fornecer informações oportunas para orientar decisões agronômicas e econômicas (Liaghat; Balasundram, 2010).

O SR firmou-se como uma das principais tecnologias da AP na identificação da variabilidade de áreas agrícolas, contribuindo para otimizar o uso de recursos e reduzir custos operacionais, embora ainda enfrente desafios ligados ao investimento inicial e à necessidade de capacitação técnica dos agricultores (Mgendi, 2024).

Um dos produtos do SR em plataforma orbital consiste em imagens multiespectrais, ou seja, imagens com múltiplas bandas espectrais que representam a refletância de diferentes faixas do espectro eletromagnético, que podem ser combinadas por meio de operações matemáticas para obter resultados que realçam aspectos dos alvos, como os Índices Espectrais. Alguns Índices Espectrais são voltados para a análise da vegetação (Índices de Vegetação - IV), e são frequentemente citados em pesquisas de AP (Radočaj *et al.*, 2023), e podem, por exemplo, contribuir na modelagem de predição de produtividade de culturas (Amaral *et al.*, 2024).

No cenário atual, a disponibilidade de produtos gratuitos de SR possibilita o acesso a dados de sensores, como o da missão *Copernicus Sentinel-2*, com 10 metros de resolução espacial e revisita de 5 dias entre as aquisições de imagens de um mesmo local (ESA, 2025). No entanto, o acesso aos dados *Sentinel-2* pela plataforma oficial *Copernicus Browser* pode ser oneroso em termos de tempo e exigir processamento adicional dos dados em outros softwares até que se tornem úteis às suas aplicações finais.

Plataformas de acesso e processamento de dados de SR, como o *Code Editor* do *Google Earth Engine* (GEE), exigem o uso da linguagem de programação *JavaScript* para acesso e processamento de dados, o que demanda conhecimentos técnicos específicos por parte do usuário. Além do uso de *JavaScript* disponível no *Code Editor*, os recursos de computação em nuvem do GEE também podem ser acessados por meio da Interface de Programação de Aplicativos (API) *Python* do

GEE, que pode ser integrada a diferentes ambientes de desenvolvimento (Gorelick *et al.*, 2017). Essa flexibilidade viabiliza a integração do GEE como módulo funcional incorporado a aplicações ou sistemas de software, ampliando suas possibilidades de uso em soluções computacionais voltadas ao tratamento e análise de dados de SR.

Softwares voltados ao processamento, análise e visualização de dados georreferenciados, conhecidos como Sistema de Informação Geográfica (SIG), são reconhecidos como ferramentas de trabalho que podem integrar dados de SR em aplicações de AP (Sood *et al.*, 2015). Entre os SIG de uso gratuito, destaca-se o QGIS em decorrência de sua ampla base de usuários e extensa gama de funcionalidades disponíveis, além da possibilidade de expansão de suas capacidades por meio de complementos (*plugins*), que funcionam como aplicativos internos da plataforma (QGIS Development Team, 2025).

A ausência de ferramentas que permitam o uso de SR diretamente no QGIS, aliada à necessidade de conhecimentos avançados de programação e ao longo tempo de processamento das imagens Sentinel-2, evidenciam a demanda por soluções de fácil utilização para acessar, processar e visualizar dados da missão *Copernicus Sentinel-2*. Nesse sentido, o objetivo deste trabalho foi apresentar e validar as ferramentas e funcionalidades do complemento RAVI por meio de um estudo de caso reproduzível no âmbito da AP, demonstrando o potencial da ferramenta em facilitar e melhorar o fluxo de trabalho de estudantes, profissionais e pesquisadores que utilizam imagens de satélite para o manejo e estudo de áreas agrícolas, além de reduzir a barreira de entrada a novos usuários deste tipo de recurso.

O estudo de caso proposto foi avaliado por meio da aplicação das principais funcionalidades do complemento e suas possíveis aplicações em 1) monitoramento agrícola, para um diagnóstico do estado atual da vegetação e tomada de decisões práticas; 2) o apoio à análise, para utilizar os resultados gráficos de perfil temporal de IV e imagens para investigar a dinâmica da produção agrícola geral e de talhões e 3) como ferramenta de extração e preparação de dados, utilizada com o propósito de subsidiar novos estudos e pesquisas.

A relevância deste trabalho evidencia-se em duas dimensões. No âmbito acadêmico, ele visa impulsionar pesquisas em SR e AP ao propor uma solução prática para a obtenção de dados que subsidiem investigações futuras. No âmbito prático, oferece uma ferramenta gratuita para monitoramento e análise de lavouras para os

produtores e profissionais, com a finalidade de reduzir o tempo despendido, a complexidade de acesso, e processamento de imagens de SR em seus fluxos de trabalho.

1.1 OBJETIVO

Desenvolver e disponibilizar uma ferramenta gratuita denominada *Remote Analysis of Vegetation Indices* (RAVI), que permite, de forma simplificada, o acesso, o processamento e a visualização de dados da constelação *Copernicus Sentinel-2* integrada com os recursos de computação em nuvem do *Google Earth Engine* (GEE), por meio de um complemento para a plataforma QGIS.

2 REVISÃO DE LITERATURA

2.1 AGRICULTURA DE PRECISÃO (AP)

A Associação Brasileira de Agricultura de Precisão e Digital (AsBraAP), em seu *website*, disponibiliza a tradução da definição de AP da *International Society of Precision Agriculture* (Sociedade Internacional de Agricultura de Precisão), como:

Agricultura de Precisão é uma estratégia de gestão que reúne, processa e analisa dados temporais, individuais e espaciais e os combina com outras informações para apoiar as decisões de gerenciamento de acordo com a variabilidade estimada para melhorar a eficiência no uso de recursos, produtividade, qualidade, rentabilidade e sustentabilidade da produção agropecuária (AsBraAP, 2025, online).

De acordo com McFadden *et al.* (2023), a AP fundamenta-se no uso de tecnologias como monitores de colheita, mapas de solo e sistemas de taxa variável, ou *Variable Rate Technology* (VRT), para quantificar e gerenciar a variabilidade espacial dentro dos talhões. Segundo os autores, a aplicação otimizada de insumos, como sementes, fertilizantes e defensivos, viabilizada por essas ferramentas, não apenas aumenta a eficiência produtiva, mas também reduz custos operacionais e impactos ambientais, como a lixiviação de nutrientes. Além disso, os autores destacam que a adoção de sistemas de direção automática e controle de linha de plantio mitiga falhas e sobreposições no campo, resultando em economia de mão de obra, redução no consumo de combustível e diminuição da fadiga do operador.

No cenário brasileiro, observa-se um descompasso entre a difusão declarada pelos produtores e o uso concreto de AP, visto que, embora 45% afirmem utilizar, apenas 15,3% aplicam de forma efetiva a amostragem georreferenciada, e, apesar de 60% adotarem piloto automático, 88% desses operam apenas com sinal aberto de GPS, sem a devida correção diferencial, conforme descrito por Molin (2017) em boletim técnico com dados obtidos pela empresa *Kleffmann Group* em 2013.

Diagnósticos setoriais, no entanto, apresentam avanços institucionais e difusão de técnicas de AP por entidades públicas e privadas, mas a adoção ainda segue limitada por custos, complexidade técnica e carência de capacitação (Silva; Silva-Mann, 2020). De acordo com Abreu e Junior (2024), a implementação de AP por pequenos e médios produtores enfrenta obstáculos significativos, como a dificuldade

de obter crédito para aquisição de tecnologias, e falta de domínio de ferramentas como sensores e sistemas de análise de dados, que não apenas reduz a eficácia das tecnologias implementadas, mas também desencadeia resistência à sua adoção.

No contexto de AP, imagens de satélite de acesso aberto podem contribuir significativamente para uma visão geral do estado das culturas, orientar ações específicas e oportunas, reduzir as perdas de produção e os impactos no meio ambiente (Segarra, 2024). Imagens da constelação *Sentinel-2*, em especial, têm se destacado, em comparação a satélites de características semelhantes, por apresentar desempenho superior em aplicações de AP (Segarra *et al.*, 2020). Desse modo, a incorporação sistemática de imagens orbitais desta constelação configura um elo entre os princípios de AP e os itens apresentados a seguir.

2.2 SENSORIAMENTO REMOTO NA AGRICULTURA

O Sensoriamento Remoto (SR) refere-se a técnica que permite a obtenção de informações sem contato físico direto com o objeto de estudo, por meio do uso integrado de sensores e de sistemas de aquisição, processamento e transmissão de dados, instalados em diferentes plataformas, como satélites e aeronaves (Novo, 2010). Dessa forma, o objetivo é estudar eventos, fenômenos e processos que ocorrem na superfície do planeta Terra, a partir do registro e da análise das interações entre a radiação eletromagnética e as substâncias que o compõem em suas mais diversas manifestações (Novo, 2010).

O SR com sensores ópticos embarcados em plataformas que orbitam a Terra coletam dados a partir da radiação eletromagnética refletida ou emitida pelos elementos da superfície terrestre (Gastauer, 2024) e, para compreender suas capacidades e importância na agricultura, quatro tipos de resoluções podem ser considerados, em definição de Meneses *et al.* (2025):

- Resolução espacial: O tamanho individual da menor feição imageada no terreno, chamado de pixel;
- Resolução espectral: aspectos relacionados a 1) quantidade de banda que o sensor possui; 2) largura da banda; e 3) posição que a banda está situada no espectro eletromagnético;

- Resolução radiométrica: medida da capacidade dos detectores de um sensor em registrar diferentes níveis de intensidade de radiância em cada pixel;

- Resolução temporal: frequência com que o sensor revisita uma área ao longo de sua vida útil.

A resolução espacial define o nível de detalhamento e o tipo de aplicação possível. Por exemplo, para identificar todas as árvores de um parque, a resolução mínima aceitável deve ser cerca de metade do diâmetro da copa da menor árvore (Jensen, 2009), e a mesma lógica poderia ser seguida para identificação falhas de plantio em culturas. Exemplos: 10 m (Sentinel-2), 30 m (Landsat-8) e 250 m (MODIS). A resolução espectral permite o cálculo dos índices espectrais (conforme discutido em seção posterior), enquanto a resolução radiométrica influencia a precisão na medição das propriedades dos objetos (Jensen, 2009). Já a resolução temporal determina a capacidade de acompanhar mudanças ao longo do tempo (Jensen, 2009); exemplos: 1 a 2 dias (MODIS), 5 dias (Sentinel-2) e 16 dias (Landsat-8).

2.2.1 Constelação Sentinel-2

O *Sentinel-2* é uma missão da Agência Espacial Europeia (ESA) composta por uma constelação de dois satélites idênticos com a mesma órbita (A e B), com 180° de diferença de fase, equipados com sensores multiespectrais (MSI) com resolução radiométrica de 12 bits. Cada sensor é composto por 13 bandas espectrais, com quatro bandas com resolução espacial de 10 m, seis bandas de 20 m e três bandas de 60 m (Tabela 1). Com o tempo de revisita de 5 dias (resolução temporal), os satélites fornecem cobertura de todas as superfícies terrestres continentais entre as latitudes 56° Sul e 82,8° Norte, possibilitando monitoramento multiespectral contínuo e carregando o legado das missões Landsat e SPOT (ESA, 2025).

Tabela 1 - Descrição das bandas espectrais do Sentinel-2

Banda	Nome	Comprimento de onda central (µm)	largura de banda (nm)	Resolução (m)
B1	Aerossóis Costeiros	0,443	20	60
B2	Azul	0,490	65	10
B3	Verde	0,560	35	10
B4	Vermelho	0,665	30	10
B5	Red Edge 1	0,705	15	20
B6	Red Edge 2	0,740	15	20
B7	Red Edge 3	0,783	20	20
B8	NIR	0,842	115	10
B8A	Red Edge 4	0,865	20	20
B9	Vapor d'água	0,945	20	60
B10	Cirrus	1,375	30	60
B11	SWIR 1	1,610	90	20
B12	SWIR 2	2,190	180	20

Fonte: Agência Espacial Europeia (2025).

As imagens Sentinel-2 são disponibilizadas pela ESA em coleções (conjunto de imagens) com diferentes níveis de correções, dentre elas a “Nível 2A Coleção 1” que fornece reflectância de superfície ortorretificada, a partir da base “fundo da atmosfera”, ou *bottom-of-atmosphere* (BOA), que inclui correções de efeitos atmosféricos (Sentinel Online, 2021). Esse produto inclui uma camada de classificação de cena, denominada *Scene Classification Layer* (SCL), que contém pixels de 20 m de resolução, em 12 níveis categóricos (Tabela 2). Cabe destacar que a SCL é uma classificação atmosférica do tipo pixel, e não um mapa de cobertura do solo no sentido estrito (Sentinel Hub, 2025). Além disso, contém indicadores de qualidade, como o metadado “*CLOUDY_PIXEL_PERCENTAGE*”, que estima o percentual de cobertura de nuvem na totalidade de cada imagem.

Tabela 2 – Classes de classificação fornecidas na SCL
Classes fornecidas pela Classificação de Cena


Sem dados (Dados ausentes)
Pixel saturado ou defeituoso
Sombras topográficas
Sombras de nuvens
Vegetação
Sem vegetação
Água
Sem classificação
Probabilidade média de nuvens
Alta probabilidade de nuvens
Cirros finos
Neve ou gelo

Fonte: Sentinel Hub (2025).

2.2.2 Índices Espectrais e de Vegetação

As bandas das imagens Sentinel-2 representam a capacidade de mensurar a refletância em faixas específicas do comprimento de onda e constituem a base das aplicações agrícolas, uma vez que a vegetação pode apresentar um perfil característico ao longo do espectro eletromagnético em função da concentração de pigmentos, estrutura celular e conteúdo de água (Figura 1). Isso ocorre porque cada um dos comprimentos de onda interage com os objetos terrestres de forma própria, resultando em diferentes intensidades de refletância, configurando a sua assinatura espectral (Meneses *et al.*, 2025).

Figura 1 - Comparativo da assinatura espectral da folha de vegetação verde sadia, estressada e severamente estressada



Fonte: Souza Filho *et al.* (2008).

A vegetação apresenta menor refletância nas bandas do visível devido à intensa absorção pela clorofila e outros pigmentos fotossinteticamente ativos, principalmente nas bandas do azul (470 nm) e do vermelho (670 nm). Enquanto no infravermelho próximo (NIR), a radiação é predominantemente espalhada, refletida e transmitida com pouca absorção, em função da estrutura do dossel, o que promove um contraste acentuado quando há cobertura completa por vegetação e um contraste mínimo sobre alvos com pouca ou nenhuma vegetação (Jensen, 2009).

Técnicas que manipulam as bandas com operações aritméticas originaram os chamados índices espectrais, desenvolvidos com o objetivo de realçar alvos e suas características específicas para diversas aplicações, como o estudo do solo (Chen *et al.*, 2025), análise urbana (Javed *et al.*, 2021) e de corpos de águas superficiais (Zhou

et al., 2017). Os índices voltados à análise da vegetação, conhecidos como índices de vegetação (IV), são reconhecidos pelo potencial de fornecer informações sobre a saúde e crescimento das lavouras (Radočaj *et al.*, 2023).


Em particular, os IVs obtidos a partir de imagens Sentinel-2 têm tido seu potencial explorado em diversos estudos direcionados à AP, como na estimativa do conteúdo de clorofila no dossel (Vincini *et al.*, 2016), no mapeamento e predição da produtividade agrícola (Perich *et al.*, 2023), predição da variabilidade da produtividade da soja (Freitas *et al.*, 2024), e na utilização como covariável em técnicas de delineamento de zonas de manejo (Melo *et al.*, 2025).

2.2.3 Perfil de Série Temporal

A frequência de revisita de sensores orbitais permite a criação de séries temporais (perfil temporal) de IV, que consistem na organização cronológica dos resultados que permitem, por exemplo, distinguir classes de culturas em algum momento durante os estágios de crescimento, com base em suas diferenças espectro-temporais impulsionadas pela fenologia, expressas nos dados de IV (Wardlow *et al.*, 2007). Além disso, perfis temporais de IV podem possibilitar o monitoramento de todo o ciclo de desenvolvimento, desde a emergência, passando pelo pico de vigor vegetativo, até a senescência ou a colheita (Esquerdo *et al.*, 2020).

A plataforma web SATVeg, por exemplo, disponibiliza o perfil temporal do NDVI (Rouse *et al.* in 1973) e do *Enhanced Vegetation Index* (EVI) (Huete *et al.*, 1994) para áreas de interesse. No entanto, o perfil gerado é restrito à América do Sul, limitado aos dois IV mencionados. Na plataforma, o usuário pode clicar no mapa para destacar os limites do pixel selecionado e visualizar o perfil temporal correspondente (Figura 2).

Figura 2 – Perfil temporal de IV na plataforma SATVeg



Fonte: Esquerdo (2020).

2.2.4 Imagem Sintética

Outro produto derivado das séries temporais do SR orbital e que tem sido aplicado em estudo agrônômicos, são as imagens sintéticas. Elas podem ser compreendidas como um dado resultante de um procedimento que envolve a agregação ou composição de múltiplas imagens (*image compositing*), empregado para gerar representações a partir de diferentes técnicas de fusão (Qiu *et al.*, 2023).

Esse procedimento já foi utilizado em contexto de AP, por exemplo, por meio dos estudos de Melo *et al.* (2025), que aplicaram uma imagem sintética de EVI, obtida a partir de dados Sentinel-2, correspondente a média das imagens de pico de vigor da vegetação em múltiplos safras produtivas, a fim de inferir a homogeneidade da cobertura vegetal ao longo das estações de crescimento.

A aplicação de imagens sintéticas também é referenciada em estudos recentes voltados à análise pedológica, como o de Silvero *et al.* (2021). Os autores demonstraram a eficácia desta abordagem ao desenvolverem as Imagens Sintéticas de Solo, ou *Synthetic Soil Image* (SYSI), que, geradas a partir de séries temporais dos satélites Sentinel-2 e Landsat-8, mostraram-se adequadas para a obtenção de mapas de propriedades do solo em regiões tropicais.

2.3 PLATAFORMAS COMPUTACIONAIS E PROCESSAMENTO EM NUVEM


O termo Sistema de Informação Geográfica (SIG) em seu surgimento no início da década de 1960, designava uma ferramenta computacional de apoio à gestão de grandes volumes de informação e à sobreposição de camadas de dados, porém, com o tempo, os SIGs evoluíram para ferramentas de análise de dados espaciais e planejamento da paisagem (Lang; Blaschke, 2009). Dentre os SIGs disponíveis gratuitamente, destaca-se o QGIS, um software de uso local em *workstations* (versão *SIG-Desktop*) cuja arquitetura permite a expansão de suas funcionalidades por meio dos cerca de 2800 disponíveis no repositório oficial (QGIS Project, 2025).

Esses complementos, desenvolvidos pela comunidade de usuários, são distribuídos livremente e permitem a ampliação dos fluxos de trabalho com o QGIS como plataforma base. Atualmente, isso é demonstrado por complementos direcionados à AP, como o *Smart-Map* (Pereira *et al.*, 2022), que possibilita gerar semivariogramas, realizar interpolações por meio de krigagem ordinária, além de definir zonas de manejo. Outro exemplo é o *Precision Agriculture Tool* (PAT) (Ratcliff *et al.*, 2019), voltado à limpeza de dados, à interpolação de mapas e à análise de imagens de SR.

Paralelamente, nos últimos anos, a computação em nuvem, definida por Mell e Grance (2011), do *National Institute of Standards and Technology* (NIST), como um modelo que permite o acesso ubíquo, conveniente e sob demanda a um conjunto compartilhado de recursos computacionais, os quais podem ser rapidamente provisionados e liberados com mínimo esforço de gerenciamento, tem impulsionado o surgimento de plataformas de geoprocessamento, como o *Google Earth Engine* (GEE).

O GEE disponibiliza um catálogo de múltiplos *petabytes* (10^{15} bytes) de imagens de satélite e dados geoespaciais, juntamente com uma infraestrutura de processamento em nuvem em escala planetária (Earth Engine, 2025). Essa abordagem possibilita o acesso às análises complexas, anteriormente restritas a especialistas com acesso a supercomputadores (Gorelick *et al.*, 2017). O acesso aos recursos do GEE pode ser realizado por meio de rotinas em linguagem de programação *JavaScript* no *Code Editor* (Figura 3) ou por *Python*, mediante sua API, em outros ambientes de desenvolvimento (Gorelick *et al.*, 2017).

Figura 3 - Ambiente de desenvolvimento do *Google Earth Engine Code Editor*, demonstrando a interface para escrita de scripts



Fonte: Gorelick *et al.* (2017).

O GEE também permite o desenvolvimento de interfaces gráficas de usuário compartilháveis para exploração e análise de dados, por meio de aplicativos denominados “GEE Apps”, acessíveis pelo navegador web (Google, 2025). Contudo, essas aplicações são limitadas aos recursos presentes no *Code Editor*, ou seja, não permitem a integração de bibliotecas externas, o que pode limitar a implementação de funcionalidades desejadas.

A convergência entre o QGIS e o GEE foi explorada por meio do complemento “GEE Plugin”, que encapsula e porta a API *Python* do GEE no QGIS e possibilita sua utilização direta, de forma semelhante ao modo como o *JavaScript* é utilizado no *Code Editor*, além de fornecer uma interface gráfica para downloads de dados do GEE (GEE Community, 2025). No entanto, não disponibiliza funcionalidades específicas para AP, como a geração de IV e de seus respectivos perfis temporais.

No contexto nacional, iniciativas buscam integrar o processamento de grandes volumes de dados de observação da Terra a ambientes de SIG *Desktop*. Um exemplo é a extensão WTSS-QGIS, desenvolvida por Anjos *et al.* (2025), que conecta a interface gráfica do QGIS ao serviço *Web Time Series Service* (WTSS) do projeto *Brazil Data Cube* (BDC). O objetivo principal dessa ferramenta é otimizar a recuperação e visualização de séries temporais de imagens de satélite, abstraindo a complexidade de comandos e scripts de programação e permitindo que usuários realizem análises extensas sobre cubos de dados multidimensionais diretamente no ambiente QGIS.

3 DESENVOLVIMENTO DO COMPLEMENTO

As funcionalidades do complemento RAVI foram desenvolvidas predominantemente em *Python*. A API *Python* do GEE foi utilizada para acesso ao catálogo de dados e capacidade de processamento em nuvem, o que viabiliza os resultados obtidos pelo complemento. Dessa forma, a integração com o QGIS ocorre por meio da comunicação entre a máquina local do usuário e os serviços do GEE, intermediada pela API.

As funcionalidades principais implementadas no RAVI incluem o cálculo de diversos IVs, o uso de perfis temporais de médias regionais aplicados a uma área de interesse, a visualização e o download de camadas para datas específicas e a criação de imagens sintéticas. O complemento também permite a integração de dados de precipitação da NASA POWER a aplicação do filtro de suavização de Savitzky-Golay para o gráfico da série temporal, além da oferta de múltiplas opções de exportação dos dados resultantes.

A seguir, apresentam-se: (i) o levantamento de requisitos que orientou as prioridades de desenvolvimento; (ii) a base de código e sua integração com QGIS-GEE; (iii) a interface de entrada de dados e as configurações, organizadas em “Passos”; e (iv) a descrição das funcionalidades implementadas. Para informações técnicas detalhadas sobre o funcionamento do complemento, o código-fonte é a referência indicada, disponível em (<https://github.com/caioarantes/ravi-qgis-plugin>). Além disso, há documentação adicional orientada a usuários disponível em www.raviqgis.org.

3.1 LEVANTAMENTO DE REQUISITOS

O levantamento de requisitos consiste na identificação e documentação das funcionalidades propostas para atender às expectativas dos clientes (usuários) (Sommerville; Sawyer, 1997). No contexto do complemento RAVI, os requisitos foram estipulados com base nas funcionalidades que justificaram o objetivo deste trabalho, e foram divididos em duas categorias.

- i. Requisitos obrigatórios (essenciais para o funcionamento e o cumprimento do objetivo principal):

- a. Seleção da Área de Interesse (AOI): permitir a importação de geometrias provenientes de arquivos locais compatíveis com o QGIS, viabilizando a integração com camadas vetoriais já carregadas no projeto;
 - b. Busca e filtragem de imagens Sentinel-2: possibilitar a seleção de imagens com base em intervalo temporal e percentual máximo de cobertura de nuvens, garantindo a qualidade e a relevância das imagens retornadas;
 - c. Geração de séries temporais de Índices de Vegetação (IV): calcular e representar a variação temporal dos IV para a AOI selecionada;
 - d. Visualização e download de imagens: permitir a exibição e exportação local de imagens multiespectrais e dos respectivos IVs, recortadas de acordo com os limites da AOI;
 - e. Geração de imagens sintéticas: criação de composições agregadas por métricas estatísticas, como média, mediana ou máximo, obtidas a partir das séries temporais de IV pixel a pixel.
- ii. Requisitos desejáveis (agregam valor e aprimoram a experiência do usuário sem constituir funcionalidades críticas ao projeto):
- a. Reconstrução e suavização de séries temporais: implementação do filtro Savitzky-Golay, para reduzir ruídos e realçar tendências fenológicas nos gráficos de série temporal (Savitzky; Golay, 1964). Essa técnica tem sido aplicada em diversos trabalhos para reconstrução e ajuste da curva fenológica (perfil temporal) de IV (Balata *et al.*, 2022; Gómez *et al.*, 2020);
 - b. Download em lote: exportação simultânea de múltiplas imagens para otimizar o fluxo de trabalho;
 - c. Composições de visualização diversificadas: oferta de diferentes combinações de bandas e paletas cromáticas para aprimorar a análise visual;
 - d. Integração de dados climáticos: inclusão opcional de informações meteorológicas de serviços online (NASA POWER), possibilitando correlações entre variáveis climáticas e o comportamento temporal da vegetação;

- e. Download de Modelo Digital de Elevação diretamente pelo complemento.

A análise do conjunto de requisitos direcionou a escolha do QGIS como a plataforma de desenvolvimento para a ferramenta proposta. Essa decisão justifica-se pela arquitetura do software, que, por meio da integração nativa com a linguagem Python que já conta diversas bibliotecas de geoprocessamento e manipulação de dados inclusas, possibilita a construção de uma interface gráfica e a comunicação com a API do Google Earth Engine, unindo o processamento em nuvem às funcionalidades nativas do QGIS. Em contrapartida, a alternativa de desenvolver uma aplicação web (WebGIS) foi descartada, visto que tal abordagem exigiria a implementação e a gestão de uma infraestrutura de *backend*, acarretando custos contínuos de hospedagem e manutenção de servidores. Além disso, a elevada complexidade técnica inerente a uma solução web demandaria uma equipe de desenvolvimento maior e multidisciplinar para assegurar a segurança e a escalabilidade a longo prazo, o que excederia o escopo e os recursos disponíveis para a execução deste trabalho.

3.2 BASE DE CÓDIGO

O desenvolvimento da base de código (o código-fonte) do *RAVI* teve início com o uso do complemento *Plugin Builder 3* (GeoApt LLC, 2025) que criou a estrutura básica do complemento, incluindo os arquivos e pastas necessários. Outro complemento, o *Plugin Reloader* (Borys Jurgiel, 2025) foi utilizado de forma recorrente para efetivar as alterações da base de código no QGIS, sem a necessidade de reiniciar a aplicação, o que agilizou o processo de testes e de depuração.


Foi utilizado um ambiente de desenvolvimento integrado, *Integrated Development Environment* (IDE), independente do QGIS, para desenvolver rotinas de processamento de dados em nuvem pelo GEE, o que permitiu o desenvolvimento incremental do código e a integração gradual à base de código, posteriormente testada no QGIS.

A interface gráfica foi desenvolvida por meio do *framework Qt Designer* (The Qt Company, 2025), que oferece um ambiente onde se clica e segura um objeto (um

widget), o move para um novo local e o solta, para a criação do *layout* gráfico. A cada edição realizada na interface por meio do *Qt Designer*, a base de código é modificada, sendo então atualizada no QGIS pelo *Plugin Reloader* e testada.

A IDE *Python* integrada ao QGIS foi utilizada para desenvolver rotinas que interagem diretamente com o QGIS (como adicionar camadas e aplicar renderizações estilizadas). Esses componentes, então, foram adicionados à base de código por meio de outra IDE, o que levou a um novo ciclo de testes e à integração com os componentes da interface gráfica no QGIS, configurando um novo ciclo de desenvolvimento (Figura 4).

Figura 4 - Diagrama do fluxo de desenvolvimento incremental e iterativo adotado para a base de código do complemento RAVI




O desenvolvimento da base de código foi estruturado em duas abordagens complementares, com o intuito de gerenciar a complexidade do projeto. A primeira abordagem foi incremental, na qual, em vez de construir o complemento em sua totalidade, o foco foi a entrega de funcionalidades de forma sequencial e dependente. Por exemplo, o incremento inicial tratou exclusivamente da autenticação com o GEE. Uma vez validado, o incremento seguinte adicionou a seleção da AOI, em seguida, a obtenção das datas com imagens disponíveis no período de busca, e assim sucessivamente.

A segunda abordagem foi iterativa, em que cada nova versão do complemento não apenas incorporava o novo incremento funcional, mas também permitia revisões e aprimoramentos de funcionalidades e rotinas já implementadas. Caso os testes revelassem falhas ou se uma rotina de processamento de dados mais eficiente fosse identificada, as correções e otimizações eram aplicadas na versão subsequente da base de código.

3.3 ENTRADA DE DADOS E CONFIGURAÇÕES

A interface de entrada de dados e configurações foi organizada em abas, com o objetivo de facilitar a compreensão e uso de cada parâmetro. As entradas de dados e os parâmetros configuráveis foram estruturados em etapas denominadas “Passos”, enumeradas de 1 a 9, com ações e propósitos definidos (Figura 5).

Figura 5 - Fluxograma de entrada de dados e configuração (Passos 1-9 + Visão Geral)



3.3.1 Autenticação (Passo 1)

Para utilizar o complemento, é necessário que o usuário possua uma conta na plataforma *Google Cloud*, com os serviços do GEE habilitados. Cabe ao usuário a responsabilidade de cumprir os termos de serviço da plataforma, que atualmente estabelecem regras que permitem o uso gratuito da plataforma para fins não comerciais e de pesquisa.

A primeira etapa da interface do complemento RAVI é dedicada ao processo de autenticação do usuário e à configuração de seu ID de projeto no *Google Cloud*. O ID de projeto é um identificador exigido pelo GEE e tem como finalidade monitorar o uso de recursos, definir limites e gerenciar potenciais custos (Google Cloud, 2025). Além disso, foi incluído um *link* para acessar uma página *web* com guias de uso e de configuração.

3.3.2 Pasta de Saída (Passo 2)

Esta etapa foi implementada para atender ao requisito técnico da funcionalidade de *download* de imagens em arquivos locais, uma vez que é necessário definir o destino dos dados obtidos via GEE para, posteriormente, carregá-los no QGIS e visualizá-los. O usuário deve especificar a pasta (diretório) onde os resultados das imagens serão salvos para avançar para a próxima etapa da interface.

O gerenciamento do diretório foi realizado por meio de rotinas em Python integradas ao complemento. Foi implementado um recurso para reutilizar o último diretório utilizado e evitar a substituição de arquivos homônimos. Para isso, a aplicação verifica a existência de arquivos com o mesmo nome e, se necessário, gera automaticamente um novo nome com a adição de um sufixo numérico, garantindo a integridade dos arquivos salvos.

3.3.3 Seleção da Área de Interesse (Passo 3)

Esta etapa foi desenvolvida com foco na delimitação da AOI, requisito que orienta a busca por imagens no GEE e baseia os subsequentes. O usuário pode desenhar geometrias diretamente no mapa do QGIS, utilizando as ferramentas de criação de camadas vetoriais do próprio software para selecioná-las na interface do RAVI, ou utilizar camadas existentes.

No desenvolvimento, esta etapa envolveu lidar com os diversos formatos de camadas vetoriais, como arquivos *shapefile* (.shp) e KML suportados pelo QGIS, e convertê-los para o formato compatível com a API do GEE, o que demandou a implementação de rotinas condicionais e ajustes nos sistemas de referência para EPSG:4326 (WGS84), padrão do GEE, por meio da classe *PyQGIS*

QgsCoordinateTransform, em uma cópia em memória do arquivo de contorno original, que também envolve a conversão para GeoJSON e a definição da variável *ee.FeatureCollection* usada no GEE para delimitar a AOI.

A área da AOI que pode ser utilizada foi limitada a 120 km², se refere ao contorno exato da AOI selecionada (e não a um retângulo que a envolve), para atender a uma limitação técnica do método de download de imagens, que impõe um limite de 32 MB por imagem (*ee.Image.getDownloadURL*).

Para facilitar a compreensão do usuário, a AOI selecionada e o limite estabelecido são exibidos para comparação e, caso a AOI selecionada exceda esse limite, é exibido um aviso.

Ainda nessa etapa, o botão "Carregar imagem mais recente disponível" foi adicionado para agilizar o monitoramento da AOI. Ao acioná-lo, o restante dos parâmetros de configuração é definido com valores padrão e a busca de imagens é executada. Em seguida, a imagem multiespectral mais recente disponível, com composição em cor verdadeira, e sua respectiva imagem NDVI são carregadas automaticamente.

Adicionalmente, nesta etapa, foi implementada a funcionalidade de obter Modelos Digitais de Elevação (MDE), de múltiplas fontes de dados disponibilizados no catálogo do GEE, permitindo o download do arquivo de altimetria com resolução espacial de até 30 metros recortado para os limites da AOI.

3.3.4 Seleção do Intervalo de Tempo (Passo 4)

A definição do período para a busca de imagens *Sentinel-2* atende a um requisito do GEE e facilita o uso pelo usuário, oferecendo opções com intervalos predefinidos (últimos 3, 6, 12 meses, etc.) e uma caixa de seleção para inserir as datas exatas de início e fim. A seleção padrão corresponde ao intervalo dos últimos 3 meses, mantendo o tempo de processamento reduzido. Selecionar apenas o período de interesse pode, ainda, reduzir o tempo de espera na busca e no processamento das imagens. No entanto, é importante notar que a geração global sistemática e operacional de produtos de Nível 2A, utilizada neste trabalho, está em andamento desde 13 de dezembro de 2018 (ESA, 2025).

3.3.5 Seleção do Índice de Vegetação (Passo 5)

A interface de seleção de IV inclui uma gama de índices predefinidos (Tabela 3), acompanhados de um breve texto explicativo para cada. Essas explicações, que incluem a fórmula matemática de cada IV e a descrição de suas principais aplicações, foram desenvolvidas em Linguagem de Marcação de Hipertexto (HTML). Além dos índices predefinidos, é possível criar índices personalizados com a construção de expressões matemáticas entre as bandas espectrais disponíveis e um conjunto de operadores e funções. A documentação adicional disponível dentro do complemento pode ser consultada para mais detalhes sobre como desenvolver os índices personalizados. O índice selecionado será utilizado para o cálculo do perfil temporal da AOI, e os resultados serão exibidos graficamente em “Painel A”.

Tabela 3 – Índices de vegetação implementados no complemento RAVI

Nome	Sigla	Fórmula	Citação Original (Autor, Ano)
Normalized Difference Vegetation Index	NDVI	$\frac{NIR - RED}{NIR + RED}$	Rouse <i>et al.</i> (1974)
Green Normalized Difference Vegetation Index	GNDVI	$\frac{NIR - GREEN}{NIR + GREEN}$	Gitelson <i>et al.</i> (1996)
Enhanced Vegetation Index	EVI	$2.5 * \left(\frac{NIR - RED}{NIR + 6 * RED - 7.5 * BLUE + 1} \right)$	Huete <i>et al.</i> (1999)
Enhanced Vegetation Index 2	EVI2	$2.5 * \left(\frac{NIR - RED}{NIR + RED + 1} \right)$	Jiang <i>et al.</i> (2008)
Soil-Adjusted Vegetation Index	SAVI	$(1 + L) * \left(\frac{NIR - RED}{NIR + RED + L} \right)$	Huete (1988)
Modified Soil-Adjusted Vegetation Index	MSAVI	$\frac{2 * NIR + 1 - \sqrt{((2 * NIR + 1)^2 - 8 * (NIR - RED))}}{2}$	Qi <i>et al.</i> (1994)
Structurally Focused Difference Vegetation Index	SFDVI	$\frac{NIR + GREEN}{2} - \frac{RED + REDEGE}{2}$	Baptista (2015)
Chlorophyll Index Green	Clgreen	$\frac{NIR}{GREEN} - 1$	Gitelson <i>et al.</i> (2003)
Normalized Difference Red Edge	NDRE	$\frac{NIR - REDEGE}{NIR + REDEGE}$	Gitelson and Merzlyak (1994)
Atmospherically Resistant Vegetation Index	ARVI	$\frac{NIR - (2 * RED - BLUE)}{NIR + (2 * RED - BLUE)}$	Kaufman and Tanré (1992)
Normalized Difference Moisture Index	NDMI	$\frac{NIR - SWIR}{NIR + SWIR}$	Gao (1996)
Normalized Burn Ratio	NBR	$\frac{NIR - SWIR}{NIR + SWIR}$	Key and Benson (1999)
Structure Insensitive Pigment Index	SIPI	$\frac{NIR - BLUE}{NIR - RED}$	Peñuelas <i>et al.</i> (1995)
Normalized Difference Water Index	NDWI	$\frac{GREEN - NIR}{GREEN + NIR}$	McFeeters (1996)
Red Edge Chlorophyll Index	ReCI	$\frac{NIR}{REDEGE} - 1$	Gitelson <i>et al.</i> (2003)
MERIS Terrestrial Chlorophyll Index	MTCI	$\frac{NIR - REDEGE}{REDEGE - RED}$	Dash and Curran (2004)
Modified Chlorophyll Absorption Ratio Index	MCARI	$\frac{((REDEGE - RED) - 0.2 * (REDEGE - GREEN)) * (REDEGE)}{RED}$	Daughtry <i>et al.</i> (2000)
Visible Atmospherically Resistant Index	VARI	$\frac{GREEN - RED}{GREEN + RED - BLUE}$	Gitelson <i>et al.</i> (2002)
Triangular Vegetation Index	TVI	$0.5 * (120 * (NIR - GREEN) - 200 * (RED - GREEN))$	Broge and Leblanc (2001)

3.3.6 Filtro de Sobreposição de Imagens (Passo 6)

As imagens *Sentinel-2* Nível 2A são disponibilizadas em cenas de 10.000 km² (100 km x 100 km) e podem não cobrir completamente a AOI, inviabilizando certas análises. Como a função de busca do GEE não realiza filtragem que mensura a proporção da AOI coberta pela cena, implementou-se, portanto, um filtro adicional. Esse filtro calcula a porcentagem de sobreposição por meio da razão entre a área em comum e a área total da AOI, assegurando que cada cena cubra adequadamente a AOI.

O cálculo da sobreposição é realizado por funções específicas da API do GEE, que determinam a área comum entre o contorno da AOI e a extensão espacial de cada imagem candidata. Dessa forma, apenas imagens cuja porcentagem de sobreposição seja igual ou superior ao limiar definido são mantidas. Definiu-se um limiar padrão de 90% para recomendar que análises iniciais apresentem alto grau de sobreposição com a AOI. No entanto, é importante mencionar que AOIs grandes ou irregulares podem dificultar a busca por imagens que atinjam um limiar elevado, uma vez que a cobertura integral de áreas extensas ou complexas é incomum. Dessa forma, o valor de sobreposição ajustável oferece ao usuário um mecanismo para equilibrar a qualidade dos dados e a disponibilidade de cenas, otimizando a seleção conforme o tamanho e o formato da AOI.

3.3.7 Opções de Buffer (Passo 7)

Este recurso foi implementado para permitir que o usuário redefina os contornos de sua AOI, especificando uma distância, em metros, para expandir (positivo) ou contrair (negativo) os contornos da área. Um *buffer* negativo reduz a área e, assim, os efeitos de borda, como a presença de carregadores, enquanto que um positivo expande para capturar o contexto e pode permitir ajustes futuros por parte do usuário no próprio QGIS.

A nova geometria é empregada em todas as funcionalidades, como nas funções de perfil temporal e de *download* de imagem, assegurando que as análises e os dados gerados considerem a AOI modificada. Por padrão, nenhum *buffer* é

aplicado; a decisão de usá-lo cabe ao usuário. Essa redefinição ocorre em cópia dos contornos em memória do GEE e não afeta os arquivos originais.

3.3.8 Filtro de Nuvem na Cena (Passo 8)

A presença de nuvens é uma causa significativa de ruído em cenas Sentinel-2. Para reduzir esse ruído e proporcionar ao usuário controle sobre os resultados obtidos pelo complemento, este filtro foi implementado para permitir que ele defina um limite percentual máximo de cobertura de nuvens mais adequado às suas análises.

Essa filtragem é realizada por meio de um indicativo de qualidade já presente no metadado de cada imagem da coleção (*CLOUDY_PIXEL_PERCENTAGE*), que representa uma estimativa da cobertura percentual de nuvens em toda a extensão da cena, de 10.000 km². Dessa forma, apenas as cenas cuja porcentagem de cobertura por nuvens em toda a cena seja igual ou inferior ao limite definido pelo usuário são mantidas na coleção para as etapas subsequentes do processamento. Dessa forma, o filtro será mais rigoroso quando definido em 0%, restringindo a coleção a imagens completamente livres de nuvens, e menos rigoroso em 100%, caso a cobertura de nuvens não seja avaliada. O valor padrão foi definido em 40%.

3.3.9 Filtro de Classificação de Cena (Passo 9)

O filtro implementado no Passo 9 representa uma tentativa de aprimorar a filtragem de imagens com presença de nuvens, de forma mais contextualizada em relação à AOI, por meio de dados da camada SCL. Dessa forma, a acurácia dessa funcionalidade depende inteiramente da confiabilidade da camada SCL original fornecida pela ESA, o que sabidamente apresenta limitações.

O algoritmo opera sobre a coleção de imagens de entrada, utilizando a seleção das classes de pixel, para definir a lista de identificadores SCL considerados "inválidos". O processo é executado para cada imagem da coleção: uma máscara booleana é gerada para a AOI, identificando os pixels como válidos ou inválidos. Em seguida, o sistema contabiliza o número total de pixels válidos (pela soma dos valores da máscara) e o número total de pixels contidos na AOI. A razão percentual de pixels válidos (válidos/total) é então calculada e anexada a cada imagem como nova

propriedade. Por fim, aplica-se à coleção a retenção apenas das imagens cuja nova propriedade seja maior ou igual ao limiar definido pelo usuário, resultando em uma nova coleção filtrada.

Opcionalmente, é possível ativar a opção "Aplicar máscara SCL para remover pixels". Quando habilitada, essa função utiliza a máscara booleana para definir como nulos (*NoData*) todos os pixels classificados como "inválidos". Essa operação de mascaramento é propagada para todos os processamentos subsequentes.

A interface do filtro permite ao usuário definir quais classes SCL devem ser consideradas para retirada da cena (inválidas), por exemplo, nuvens e sombras de nuvens, e estabelecer um limiar de aceitação em percentual total. Esse limiar define a proporção mínima de pixels "válidos" que uma imagem deve conter na AOI para ser mantida na coleção.

Dessa forma, a filtragem é mais rigorosa quando ajustada em 100% e sem efeito quando ajustada em 0%. O valor padrão deste filtro é de 80%, o que implica o descarte de imagens com mais de 20% de pixels inválidos na AOI. Este valor, combinado com o valor padrão do filtro de nuvens em cena descrito no item anterior, apresenta desempenho médio na eliminação de ruído por nuvens e será discutido em maior detalhe em uma seção posterior. Recomenda-se que os usuários explorem alternativas de configuração de acordo com suas necessidades.

3.3.10 Filtro de Imagem Única

O filtro de imagem única foi implementado para eliminar redundâncias decorrentes de múltiplas cenas quase idênticas adquiridas pela constelação Sentinel-2 em um mesmo instante orbital, com diferença de frações de segundos entre si, que não agregam informação adicional, mas aumentam o volume de dados e o tempo de processamento.

O complemento identifica e agrupa essas imagens equivalentes, mantendo apenas uma cena representativa por data de aquisição, selecionada com base em critérios hierárquicos: primeiramente, conserva-se a imagem com maior percentual de cobertura da Área de Interesse (AOI), calculado conforme o filtro de sobreposição de imagens (Passo 6); caso haja igualdade nessa métrica, a imagem mais recente é priorizada. Esse procedimento é executado automaticamente sem necessidade de

configuração pelo usuário, garantindo que a coleção final retenha apenas uma imagem por data efetiva, o que reduz redundâncias, otimiza o desempenho do complemento e assegura maior coerência temporal às análises subsequentes.


3.3.11 Visão Geral

Esta aba da interface foi desenvolvida para oferecer um resumo das opções de entrada de dados e configurações do RAVI, consolidando as abas anteriores em uma única janela, que permite revisar o conjunto de configurações possíveis. Usuários recorrentes podem utilizar o botão “Pular Etapas”, localizado no Passo 3, para acessar diretamente a visão geral e realizar as configurações diretamente nela.

3.4 FUNCIONALIDADES ACESSÍVEIS NA ABA PAINEL


Após a inserção dos dados e das configurações, ao clicar em “Executar análises” na aba “Visão Geral”, inicia-se o processamento no GEE e, após o retorno dos resultados ao QGIS, a aba “Painel” é habilitada. As opções disponíveis na aba “Painel” foram categorizadas de “A” a “H” (Figura 6) para fins de identificação e descrição nos próximos itens.

Figura 6: Interface da aba 'Painel' do complemento RAVI, com a localização das principais funcionalidades de análise e exportação



A aba 'Painel' atua como um centro de controle interativo por meio de interações do tipo “apontar e clicar” do usuário com o complemento e instrui um fluxo de envio de requisições para processamento em nuvem no GEE, o retorno dos resultados para visualização no QGIS e/ou armazenamento no sistema local (Figura 7). Os itens a seguir detalham cada uma dessas funcionalidades.

Figura 7: Diagrama de fluxo das funcionalidades da aba 'Painel', ilustrando a interação entre o QGIS, o GEE e o sistema do usuário



3.4.1 Perfil Temporal de IV (Painel A)

O perfil temporal de IV decorre da coleção resultante da busca por imagens. O IV desejado é calculado por pixel, por meio de operações aritméticas mapeadas à coleção (com a função *map()* do GEE, usada para aplicar operações a cada imagem de uma *ee.ImageCollection*, aproveitando o processamento paralelo em nuvem). Em

seguida, para cada imagem, o valor médio do IV para a AOI é calculado por um redutor de média (no GEE, um redutor (ee.Reducer) é uma classe usada para agregar dados em várias dimensões, incluindo tempo, espaço, bandas dentro de uma imagem ou atributos dentro de uma ee.FeatureCollection).

Esses valores calculados são agregados à coleção como propriedades associadas a cada imagem. A extração desses dados ocorre por meio de requisições assíncronas, que retornam os valores em listas estruturadas. Posteriormente, essas listas são convertidas em formato de *dataframe*, uma estrutura de dados tabular da biblioteca Pandas, empregada para facilitar a manipulação das informações.

Uma vez estruturados, os dados são processados e preparados para exibição gráfica por meio de recursos da biblioteca *Plotly*, que possibilita a criação de visualizações interativas e dinâmicas. A renderização dessas visualizações é realizada com o uso do *widget QWebView*, componente do *Qt Design* que emula um navegador de internet integrado ao próprio complemento.

3.4.2 Visualização e Download de Imagens em Data Específica (Painel B)

Cada ponto do perfil temporal do IV, exibido no “Painel A”, corresponde a uma data com imagem disponível na coleção resultante da busca. Essa funcionalidade tem como foco habilitar o download e a visualização das imagens multiespectrais (com composição de cor verdadeira) dos índices de vegetação selecionados, na data selecionada. Esse processo gera e transfere dados GeoTIFF, que podem ser armazenados opcionalmente na máquina dos usuários e visualizados no QGIS.

Para camadas multiespectrais, o complemento solicita ao GEE o download do arquivo já recortado ao contorno da AOI e, em seguida, o carrega no QGIS como camada do projeto para visualização. Um padrão predefinido é aplicado para mapear as bandas, com ajuste de contraste, em composição de cor verdadeira.

No caso de camadas de IV, o complemento envia as instruções de cálculo ao GEE por meio de expressões aritméticas, exporta o arquivo e aplica a renderização de banda simples em falsa cor, utilizando a paleta de cores predefinida para otimizar a visualização. A seleção do índice para esse recurso não está limitada ao índice exibido no gráfico do perfil temporal, e pode ser alternada para qualquer IV disponível na caixa de seleção.

O complemento assegura que o GeoTIFF seja tratado como temporário, na opção de visualização, salvando os arquivos na pasta temporária do sistema operacional, ou, na opção de download, no diretório selecionado no Passo 2. O processo é acionado como descrito por imagem individual ou em lote, caso em que é aplicado a todas as imagens disponíveis automaticamente.

3.4.3 Opções de Imagem Sintética (Painel C)

A imagem sintética é gerada por meio da agregação pixel a pixel da coleção de imagens, do valor do IV ao longo do perfil temporal. A imagem resultante representa a métrica definida (média, máximo, etc.) calculada sobre a pilha de pixels em um mesmo local, em toda a AOI. O resultado é uma imagem composta (sintética) que derivada dos padrões temporais agregados, de acordo com a métrica selecionada, e é exportada localmente e visualizada, com renderização de banda simples em falsa cor, de forma análoga à funcionalidade do “Painel B”.

3.4.4 Opções de Remoção de Datas (Painel D)

A seleção de datas é realizada em uma interface interativa que permite escolher manualmente as observações temporais a serem incluídas em todas as outras análises que envolvem o conjunto de imagens da coleção. O usuário pode filtrar o perfil temporal removendo datas indesejadas ou selecionando períodos específicos por meio de caixas de seleção. Essas caixas são organizadas hierarquicamente por ano e mês, em que cada data disponível no perfil temporal possui uma caixa individual, e há caixas adicionais para seleção agregada nos níveis de mês e de ano. Essa seleção tem como objetivo filtrar as datas exibidas no “Painel A” e não altera a coleção do GEE, exceto quando novos cálculos sobre a coleção forem acionados pelos “Painel C” ou “H”.

3.4.5 Opções de Filtro Savitzky-Golay (Painel E)

O filtro *Savitzky-Golay* foi implementado para a reconstrução suavizada do perfil de IV da série temporal (Painel A), reduzindo alterações abruptas (ruído)

enquanto preserva características relevantes, como picos e tendências. Ele é aplicado por meio da biblioteca *SciPy*, que ajusta polinômios locais aos dados em uma janela deslizante. A ordem do polinômio e o tamanho da janela são configuráveis da interface e controlam o grau de suavização resultante no perfil temporal exibido no “Painel A”, sobreposto ao perfil original, o que permite a comparação. A configuração padrão foi definida para que a suavização seja o mais tênue possível.

3.4.6 Opções de dados NASA POWER (Painel F)

Esta funcionalidade foi implementada para integrar dados climáticos à análise de perfis temporais de IV. Quando acionada, uma requisição é enviada à API *Python* NASA POWER, utilizando a latitude e a longitude do centroide da AOI, além do intervalo de datas, como parâmetros. Os dados retornados incluem a precipitação e as temperaturas mínimas e máximas diárias (disponíveis na exportação de dados), organizados em um *dataframe*.

O complemento organiza os dados de precipitação em acumulados mensais e atualiza o “Painel A”, exibindo gráficos de barras sobrepostos para apresentar a precipitação sobreposta ao perfil temporal de IV. Embora apenas os dados de precipitação sejam exibidos graficamente, as temperaturas mínimas e máximas também constam nos dados tabulados disponíveis para exportação.

É importante observar a resolução espacial NASA POWER é de 0.5° por 0.625° (cerca de 50×55 km). Dessa forma, os dados obtidos representam uma estimativa da média dessa área e não substituem estações meteorológicas e não podem ser usados para confrontar eventos climáticos específicos em campo.

3.4.7 Opções para exportar dados tabulares (Painel G)

Os valores do gráfico do perfil temporal no “Painel A” podem ser exportados diretamente em formato tabular. A imagem do gráfico também pode ser salva, desde que seja aberta em um navegador de internet externo instalado no computador. Isso foi implementado porque o *widget* *QWebView*, embora simule um navegador integrado ao complemento, não possui todos os recursos necessários para realizar o

download direto. No entanto, abrir o gráfico em um navegador pode ser vantajoso, pois permite ajustes manuais nas dimensões.

3.4.8 Opções para Alternar IV e Focar em Área (Painel H)

Esta funcionalidade foi desenvolvida para otimizar o processamento computacional em alguns fluxos de trabalho específicos, como a exploração dos diferentes IV disponíveis, ao evitar o reproprocessamento dos filtros e preservando qualquer seleção de datas aplicada anteriormente. Exemplo de uso: Usuário obtém uma série temporal NDVI para uma AOI (fazenda) e após inspecionar algumas imagens decide removê-las da série temporal por conta de ruídos observados; em seguida gostaria de obter nova série temporal com outro índice, mantendo a seleção de imagem já aprimorada manualmente; para isso, faz uso desta funcionalidade. Além disso, é possível utilizá-la para obter um novo perfil temporal de uma subdivisão da AOI original (como um talhão), ao selecionar o contorno do talhão e executar o novo cálculo com a coleção de imagens existente (sem necessidade de nova busca de imagens e processamento de filtros), o que reduz tempo de espera pelos dados processados.

3.5 ANÁLISE MULTIFEIÇÃO E ANÁLISE DE PONTOS

As funcionalidades "Análise de Multifeição" e "Análise de Pontos" foram implementadas para possibilitar a análise comparativa de perfil temporal de diferentes regiões em múltiplas escalas. São recursos disponibilizados em abas individuais da interface, acessíveis após a disponibilização e operação do "Painel", e operam de forma análoga ao cálculo de perfis temporais em toda a AOI no "Painel A".

Na "Análise Multifeição", a AOI deve ser uma camada vetorial do tipo multipolígono, contendo um campo na tabela de atributos para identificação individual de cada polígono (feição). Ao executar essa análise, o complemento utiliza um recurso do QGIS para dividir as feições, armazenando-as individualmente em memória temporária, e processar cada uma como uma nova AOI, tendo seu perfil temporal calculado e exibido sobreposta, com legendas identificadoras.

Para a "Análise de Pontos", foi implementado um recurso de captura de coordenadas, ativado ao clique do usuário no mapa do QGIS. Ao ser ativado, o recurso permite ao usuário clicar no mapa e o complemento captura a coordenada geográfica, adiciona um marcador com cor aleatória e define uma nova AOI circular cuja área contém um pixel. A cada clique, um novo perfil temporal é calculado para a nova AOI gerada e adicionado ao gráfico, em cor correspondente ao marco adicionado ao mapa e utilizando as coordenadas como identificador na legenda. O gráfico da AOI original também é exibido para comparação, e há um botão que permite reiniciar a análise e remover os marcadores.

A opção de remoção de datas está disponível em ambas as abas, correspondente ao mesmo recurso do "Painel D". O botão duplicado oferece a conveniência ao permitir a aplicação da seleção de datas sem a necessidade de alternar entre abas, e qualquer alteração realizada é refletida no "Painel A". As opções para exportar o perfil temporal em ambas as abas também estão disponíveis e funcionam de forma análoga às do "Painel G".


4 ESTUDO DE CASO

O estudo de caso foi realizado na plataforma QGIS (versão 3.40.12), utilizando o complemento RAVI (versão 4.1), instalado via repositório oficial. O objetivo principal foi demonstrar as funcionalidades do complemento, aplicando-as para verificar o atendimento aos requisitos estipulados, além de discutir a possível aplicabilidade dos dados obtidos. No entanto, ressalta-se que não há a pretensão de esgotar as possibilidades de uso da ferramenta. Assim, os resultados apresentados são interpretados como evidências iniciais de sua viabilidade.

4.1 CARACTERIZAÇÃO DA ÁREA DE ESTUDO

As análises foram aplicadas em uma área de produção agrícola, que possui uma variabilidade espacial e temporal compatível com o uso do RAVI, denominada São José, em Cosmópolis, Estado de São Paulo ($22^{\circ}41'55.16''$ S, $47^{\circ}10'34.15''$ W). A área foi delimitada por uma camada multipolígono, que contém os limites dos talhões destinados à produção comercial de grãos, totalizando aproximadamente 104 hectares (Figura 8).

Figura 8 - Localização da área de estudo São Jose, no Estado de São Paulo, município de Cosmópolis



4.2 APLICAÇÃO PRÁTICA 1: MONITORAMENTO OPERACIONAL

A primeira aplicação teve como objetivo simular uma rotina de monitoramento agrícola operacional, realizada com data de referência em 07 de janeiro de 2025. O procedimento iniciou-se com a autenticação e definição da Área de Interesse (AOI), seguida da execução da funcionalidade “Carregar imagem mais recente disponível”. Esta etapa visou demonstrar a consolidação do fluxo de busca e filtragem, gerando a composição em cor verdadeira, o mapa de NDVI e o perfil temporal dos últimos três meses.

Adicionalmente, para verificar a capacidade da ferramenta em detalhar a variabilidade espacial intra-talhão, incluiu-se uma etapa de análise focada. Selecionou-se uma sub-região da área (Talhão 2) e utilizou-se a funcionalidade de alternância de índices para gerar e visualizar de GNDVI. Este procedimento teve como finalidade permitir uma análise comparativa de sensibilidade entre o NDVI e o GNDVI na detecção de heterogeneidade da cobertura vegetal na data estipulada.

4.3 APLICAÇÃO PRÁTICA 2: ANÁLISE RETROSPECTIVA E COMPARATIVA

A segunda aplicação teve como finalidade demonstrar as rotinas de análise temporal em múltiplas escalas, utilizando a coleção de imagens resultante dos filtros aplicados pelo RAVI em sua configuração padrão, para os períodos de 1 ano (07 de janeiro de 2024 a 07 de janeiro de 2025) e 3 meses (07 de setembro de 2024 a 07 de janeiro de 2025).

Foi utilizada a ferramenta “Análise Multifeição”, projetada para processar múltiplas feições poligonais (talhões). Essa ferramenta foi aplicada à camada vetorial dos talhões da área de estudo, permitindo a geração de dados para a comparação de comportamento espectro-temporal entre as diferentes unidades de cultivo.

Na sequência, aplicou-se a ferramenta “Análise de Pontos”, que permite capturar coordenadas diretamente no mapa e extrair o perfil temporal em nível de pixel. Cada clique no mapa adiciona um marcador e calcula a série temporal correspondente ao pixel mais próximo das coordenadas geográficas. Esse recurso foi utilizado para gerar dados de variabilidade interna de um mesmo talhão.

4.4 APLICAÇÃO PRÁTICA 3: EXTRAÇÃO DE DADOS PARA ANÁLISES EXTERNAS

Nesta aplicação, adaptou-se parte da metodologia utilizada nos estudos de Melo *et al.* (2025), evidenciando a aplicabilidade do RAVI em fluxos de trabalho de AP. Cabe ressaltar que a área São José, deste estudo de caso, corresponde a uma das duas áreas experimentais analisadas na pesquisa de Melo *et al.* (2025). O procedimento iniciou-se pela análise da série temporal gerada pelo complemento, de 01 de janeiro de 2019 a 01 de janeiro de 2024, visando à identificação das imagens de pico de EVI utilizado no estudo (não foi especificado como foram identificadas). Ressalta-se que, apesar da disponibilidade dessas datas no estudo original, a determinação autônoma das datas via RAVI foi realizada propositalmente para validar a capacidade técnica da ferramenta em auxiliar a identificação sem dependência de informações prévias.


Uma vez definidas as datas de interesse, utilizou-se a funcionalidade “Remoção de datas” (Painel D) para restringir a coleção apenas às imagens correspondentes. Posteriormente, a ferramenta “Imagem Sintética” (Painel C) foi aplicada para processar a coleção filtrada, gerando a imagem sintética representativa da média do EVI entre as imagens e posteriormente comparada com a imagem do estudo de referência.

5 RESULTADOS E DISCUSSÃO

5.1 USABILIDADE E INTEGRAÇÃO COM O GEE


O complemento RAVI foi executado de forma estável no ambiente do QGIS versão 3.34, mantendo comunicação constante com a infraestrutura em nuvem do GEE. O processo de autenticação (Figura 9) foi concluído em poucos segundos (após a criação da conta no GEE e configuração do ID de projeto) e representou o primeiro contato entre o ambiente local e o serviço de nuvem.

Figura 9 – Interface introdutória do complemento RAVI com orientação sobre autenticação



Após a autenticação, a AOI foi definida a partir da camada vetorial multipolígono que contém os limites dos talhões da área São José, previamente disponível no projeto QGIS ativo (Figura 10). Esse procedimento, a partir da interface do complemento, confirmou a integração direta entre os recursos de gestão de camada vetorial do QGIS, arquivos correspondentes no sistema local, e as rotinas de carregamento de geometrias do GEE, exemplificando o êxito da implementação dessa capacidade preestabelecida como requisito obrigatório.

Figura 10 – Seleção da AOI no complemento RAVI a partir de uma camada vetorial disponível no QGIS



5.2 APLICAÇÃO PRÁTICA 1: MONITORAMENTO OPERACIONAL

Após o acionamento da funcionalidade “Carregar imagem mais recente disponível”, o complemento realizou automaticamente as etapas de:

1. aplicação dos filtros de sobreposição da AOI com a coleção Sentinel-2, de cobertura de nuvens e de classificação de cena, todos em configuração padrão;
2. seleção da imagem mais recente válida dentro do período definido;
3. recorte da cena de acordo com os limites da AOI;
4. cálculo do índice de vegetação para a janela temporal de 3 meses de NDVI (seleção padrão);
5. carregamento das camadas processadas no ambiente QGIS para visualização.


Essa sequência de etapas realizadas evidencia que o RAVI foi capaz de abstrair a complexidade das rotinas implementadas, ao permitir ao usuário obter, com um único clique, dados visuais prontos para análise.

A imagem é exibida em composição de cor verdadeira na área de trabalho do QGIS, embora todas as bandas multiespectrais estejam disponíveis (o que permite outras composições definidas manualmente pelos usuários). A data da imagem, 31 de dezembro de 2024, indica que o intervalo de 8 dias entre a captura e a execução

desta análise, realizada em 7 de janeiro de 2025, é superior à resolução temporal do sensor (de 5 dias).


Isso implica que a imagem recuperada não é a mais recente adquirida pela constelação Sentinel-2, pois o intervalo máximo em condições ideais seria de seis dias (cinco de revisita somados à latência de ingestão na plataforma). O resultado obtido reflete, portanto, a última cena que satisfaz os critérios de qualidade impostos pelos filtros padrão do complemento. Na análise visual, a composição em cor verdadeira validou a ausência de ruídos atmosféricos, permitindo uma interpretação segura do NDVI. Este, por sua vez, evidenciou a heterogeneidade espacial da área, destacando manchas de menor vigor vegetativo nos talhões da porção norte (Figura 11).

Figura 11 - Composição em cor verdadeira e do NDVI para a área São José, em 31 de dezembro de 2024



No perfil temporal de NDVI, essa imagem mais recente corresponde ao valor de 0,85, o mais alto da série (Figura 12). Esse resultado possivelmente indica que, na data em questão, a safra de verão ainda não havia entrado em senescência.

Figura 12 - Perfil temporal do NDVI para a área São José, referente ao período de outubro de 2024 a janeiro de 2025 na interface do RAVI




O Talhão 2, selecionado por exibir a maior uniformidade visual na Figura 11, foi submetido a uma análise aprofundada. O objetivo foi demonstrar que, mesmo em áreas aparentemente homogêneas, é possível destacar variabilidade através da exploração da exploração do IV disponível e com técnicas de renderização visual disponíveis no QGIS. Por meio da funcionalidade 'Focar em região' (Painel H), extraíram-se as camadas de NDVI e GNDVI recortadas para os limites deste talhão, mantendo a data de referência. Adicionalmente, aplicou-se um *buffer* negativo de 20 metros para mitigar o efeito de borda.

Em seguida, foram ajustados os parâmetros de renderização por meio das propriedades de camada no QGIS, definindo os limites da paleta de cor com a renderização “média $\pm$ (desvio padrão) $\times$ 2” (Figura 13). Nota-se que em ambas camadas, há variabilidade relativa no talhão, porém na imagem GNDVI o lado leste se destaca por apresentar menores valores deste IV em relação ao lado oeste.

Dessa forma, um mapa poderia ser gerado no QGIS para orientar um profissional de campo a vistoriar essa região, e identificar possíveis causas, como a presença de pragas ou estresse nutricional e, se necessário, implementar as correções adequadas. Esses resultados evidenciam o potencial da aplicação do RAVI em contextos que demandam monitoramento de cultura.

Figura 13 - Mapas de NDVI e GNDVI, respectivamente, para o talhão 2 na área São José, em 31 de dezembro de 2024




5.3 APLICAÇÃO PRÁTICA 2: ANÁLISE RETROSPECTIVA E COMPARATIVA

Nesta aplicação, a funcionalidade de “Análise Multifeição” foi empregada para investigar a dinâmica relativa do vigor vegetativo entre os talhões entre 07 de janeiro de 2024 e 07 de janeiro de 2025 (Figura 15). Observam-se valores próximos de NDVI entre as áreas nos meses de janeiro e fevereiro (diferença inferior a 0,1), indicando uniformidade nas condições da cobertura vegetal.


Posteriormente, nota-se uma acentuada divergência entre os perfis temporais, especialmente entre março e junho de 2024, com amplitudes entre os talhões superiores a 0,5. Nesse intervalo, enquanto algumas áreas apresentam índices inferiores a 0,2, os talhões 9 e 10 exibem valores superiores a 0,7, possivelmente indicando adoção de diferentes estratégias de manejo ou ciclos fenológicos distintos entre as parcelas.

Figura 15 - Perfis temporais comparativos do NDVI para os talhões da área São José, gerados pelo complemento RAVI com a funcionalidade “Análise Multifeição”



Com o objetivo de fornecer dados visuais das possíveis distinções de manejo, utilizou-se o RAVI para visualizar duas cenas em composição de cor verdadeira (Figura 16). A primeira cena revela a ausência de vegetação verde na maior parte das parcelas, contrastando com os talhões 4, 6 e 8, que mantêm cobertura verde parcial. Cerca de 40 dias depois, a dinâmica se alterou: os talhões 4, 6 e 8 deixaram de apresentar tonalidades verdes, enquanto os talhões 9 e 10 (e parcialmente o 11) exibiram uma tonalidade verde. Esse padrão visual é compatível com o desenvolvimento inicial de uma cultura agrícola ou com a proliferação de plantas espontâneas.

Figura 16 - Comparativo visual da cobertura do solo na área São José entre 3 de março e 13 de abril de 2024



A funcionalidade “Análise de Pontos” foi aplicada ao talhão 9, selecionado devido à evidente variabilidade intratalhão observada na imagem de NDVI (Figura 11) entre 07 de setembro de 2024 e 07 de janeiro de 2025. Para investigar essa heterogeneidade, selecionaram-se três pontos distintos na área, extraíndo-se as respectivas séries temporais em nível de pixel (resolução de 10 m, correspondendo a 100 m²). O gráfico gerado no RAVI permitiu observar que o ponto superior (Ponto 1), região de menor valor de NDVI na imagem, apresentou um perfil temporal defasado em relação ao ponto intermediário (Ponto 2), que por sua vez apresentou um perfil defasado em relação ao ponto inferior (Ponto 3) (Figura 17).

Embora a causa exata possa ser multifatorial e exija validação de campo, é possível levantar hipóteses que variam desde o atraso na semeadura até diferenças de textura e fertilidade do solo. Ressalta-se que a distância entre os pontos amostrados é de aproximadamente 70 metros, embora a resolução espacial do Sentinel-2 permitisse distinções de até 10 metros.

Figura 17 - Resultado da 'Análise de Pontos' para o talhão 9, exibindo a localização de pontos amostrais sobre o mapa de GNDVI e seus respectivos perfis temporais



Além da seleção espacial direta, a funcionalidade suporta a entrada manual de coordenadas, permitindo o monitoramento de experimentos agrônômicos em pontos previamente georreferenciados. Essa precisão no posicionamento amostral, somada à funcionalidade de exportação tabular, demonstra o potencial do RAVI como instrumento de mineração e preparação de dados para estudos subsequentes.

5.4 APLICAÇÃO PRÁTICA 3: EXTRAÇÃO DE DADOS PARA ANÁLISES EXTERNAS

A execução da análise para o intervalo de cinco anos (01 de janeiro de 2019 a 01 de janeiro de 2024) permitiu demonstrar a efetividade das rotinas de filtragem do RAVI frente a um grande volume de dados. Nota-se que foi implementado um recurso para fornecer transparência aos resultados dos mecanismos de filtragem de imagens, apresentada ao usuário por meio de um relatório de contagem ao final de cada filtro aplicado (Figura 18).

Figura 18 - Relatório de filtragem da redução quantitativa da coleção de imagens após a aplicação sequencial dos filtros de nuvem, sobreposição, classificação de cena (SCL) e imagem única

The screenshot displays the QGIS RAVI - Análise Remota de Índices de Vegetação interface, showing the sequential filtering steps for image collection reduction. The interface is divided into several tabs: Passo 1, Passo 2, Passo 3, Passo 4, Passo 5, Passo 6, Passo 7, Passo 8, Passo 9, Visão geral, Painel, Análise de Pontos, and Análise Multifeição. The current step is Passo 9, which is titled 'Limiar Percentual de Pixels Válidos dentro da Área de Interesse: (Valor mais alto aplica filtragem mais rigorosa) - Passo 9'. The interface shows the following settings and results:

- Área de Interesse - Passo 3:** AOI: São José
- Intervalo de tempo (ano/mês/dia) - Passo 4:** De: 2019/1/1 até: 2024/1/1
- Índice de vegetação - Passo 5:** Índice: EVI
- Limiar de sobreposição de imagens com a área de interesse: (Valor mais alto aplica filtragem mais rigorosa) - Passo 6:** 100%
- Buffer da AOI (metros):** Buffer negativo (contra)
- Limite Percentual de Pixels Nublados: (Valor mais alto aplica filtragem mais rigorosa) - Passo 8:** 20%
- Limiar Percentual de Pixels Válidos dentro da Área de Interesse: (Valor mais alto aplica filtragem mais rigorosa) - Passo 9:** 95%
- Classes SCL a incluir: (Classes a serem consideradas como inválidas dentro da AOI)**
 - ☒ Sombras de nuvens
 - ☒ Média probabilidade de nuvens
 - ☒ Alta probabilidade de nuvens
 - ☒ Cirrus fino
 - ☒ Pixel saturado ou defeituoso
 - ☐ Vegetação
 - ☐ Não-Vegetação
 - ☒ Sem dados (dados ausentes)
 - ☒ Neve ou gelo
 - ☐ Sombras topográficas
 - ☐ Água
 - ☐ Não classificado

A pop-up window titled 'Resultados da busca' shows the following results:

- Tamanho da coleção antes de qualquer filtro: 1446
- Tamanho da coleção após filtro de limite de nuvem na cena (Passo 8): 694
- Tamanho da coleção após filtro de sobreposição com a AOI (Passo 6): 583
- Tamanho da coleção após filtro SCL (Passo 9): 522
- Tamanho da coleção após manter apenas datas únicas: 264

The interface includes buttons for 'Cancelar (permanecer nesta aba)', 'OK (ir para a próxima aba)', 'Voltar', 'Aplicar máscara SCL para remover pixels', and 'Executar'.


Para o período de cinco anos, a busca inicial no catálogo do GEE identificou um total bruto de 1446 cenas. A primeira etapa de redução consistiu na aplicação do filtro de nuvens na cena (Passo 8) baseado no metadado de cobertura global da imagem, que descartou as aquisições com mais de 20% de obstrução atmosférica por nuvem, resultando em 694 imagens.

Sobre este conjunto, aplicou-se o filtro de sobreposição (Passo 6), configurado em 100 %, que eliminou cenas que não cobriam totalmente a AOI, reduzindo a coleção para 583 imagens. Em seguida, o filtro de classificação de cena (Passo 9) analisou a classificação específica dos pixels dentro da AOI, mantendo apenas aquelas com pixels válidos acima do limiar definido de 95%, resultando em 522 cenas remanescentes.

Por fim, o algoritmo executou o filtro de imagem único, removendo redundâncias temporais. O resultado final foi uma coleção consolidada de 264 imagens, utilizada no cálculo do perfil temporal (Figura 19).

Com a coleção obtida, o perfil temporal de EVI gerado evidenciou os ciclos produtivos da cultura ao longo das safras e, em combinação com os recursos de visualização de imagens em data selecionada (Painel B), permitiu a inspeção visual das imagens e a seleção precisa das datas correspondentes aos picos vegetativos, conforme a metodologia de referência.


Figura 19 - Perfil temporal de EVI resultante de 01 de janeiro de 2019 a 01 de janeiro de 2024



A determinação das datas de pico vegetativo apresentou alta concordância com o estudo de referência, divergindo em apenas uma ocasião. Corroborou-se a inviabilidade de obtenção de dados para 2019 devido à cobertura de nuvens, o que justificou a adoção da mesma estratégia do estudo original: a seleção de duas imagens para o ano de 2022, englobando a segunda safra. O conjunto temporal final foi composto por: 20/06/2020, 23/02/2021, 15/02/2022 (em contraste com 21/01/2022 do estudo de base), 30/06/2022 e 25/06/2023.

Subsequentemente, aplicou-se um *buffer* negativo de 15 metros e processou-se a coleção via funcionalidade 'Imagem Sintética', gerando o mapa EVI com métrica “média”, renderizado no QGIS. Após o ajuste manual da paleta de cores de renderização no QGIS para fins de equiparação visual com o estudo de base (Figura 20a), a comparação com o resultado de referência (Figura 20b) revela alta similaridade nos padrões espaciais.

Figura 20 – Comparativo visual entre imagens sintéticas representativas da média do EVI: a) Resultado gerado pela funcionalidade "Imagem Sintética" do complemento RAVI; b) Resultado apresentado por Melo *et al.* (2025)



Embora as imagens não sejam estritamente idênticas, provavelmente devido à presença de uma data divergente na composição da média temporal, o resultado demonstra a efetividade do RAVI em operacionalizar uma metodologia de alta complexidade técnica que, em ferramentas como o *Code Editor* do GEE, exigiria o domínio de codificação de rotinas *JavaScript*.

6 CONSIDERAÇÕES FINAIS

O acesso e processamento de dados da constelação *Copernicus Sentinel-2*, organizadas em um fluxo de trabalho, foram implementadas no complemento para a plataforma QGIS, denominado RAVI. Os detalhes de desenvolvimento foram apresentados e o estudo de caso indicou que o complemento é apto para obter imagens e dados processados para o auxílio do manejo e pesquisa agrícola. Assim, embora exija cadastro no GEE, o RAVI dispensa aprender programação para as funcionalidades do seu escopo, otimizando o tempo de aquisição e o processamento de imagens Sentinel-2. Trabalhos futuros podem incluir a ampliação de funcionalidades relacionadas a suavização da série temporal, melhorias de interface de usuário para aprimorar a usabilidade, e a inclusão de outras bases de dados, como outros sensores e fontes de dados climáticos.

REFERÊNCIAS

ABREU, L. A.; SILVA JUNIOR, M. P. Dificuldades de acesso às ferramentas e tecnologia da agricultura de precisão para pequenos e médios produtores. **Diálogo e Interação**, Cornélio Procópio, v. 18, n. 2, p. 121-144, 2024.

AMARAL, L. R. *et al.* Remote sensing imagery to predict soybean yield: a case study of vegetation indices contribution. **Precision Agriculture**, v. 25, n. 5, p. 2375-2393, 2024. DOI:10.1007/s11119-024-10174-5. Disponível em: https://www.researchgate.net/publication/382624132_Remote_sensing_imagery_to_predict_soybean_yield_a_case_study_of_vegetation_indices_contribution. Acesso em: 3 nov. 2025.

ANJOS, A. E. *et al.* WTSS-QGIS: uma extensão para recuperação e visualização de séries temporais de imagens de satélite no ambiente QGIS. *In*: SIMPÓSIO BRASILEIRO DE SENSORIAMENTO REMOTO, 21., 2025, Salvador. **Anais [...]**. São José dos Campos: INPE, 2025. Disponível em: <https://proceedings.science/p/197329?lang=pt-br>. Acesso em: 13 dez. 2025.

ASSOCIAÇÃO BRASILEIRA DE AGRICULTURA DE PRECISÃO E DIGITAL (AsBraAP). **Definições de agricultura de precisão**. 2025. Disponível em: <http://asbraap.org/index.php?page=ap>. Acesso em: 3 nov. 2025.

BALATA, D. *et al.* Using satellite NDVI time-series to monitor grazing effects on vegetation productivity and phenology in heterogeneous mediterranean forests. **Remote Sensing, Basel**, v. 14, n. 10, 2022. DOI: 10.3390/rs14102322. Disponível em <https://www.mdpi.com/2072-4292/14/10/2322>. Acesso em: 3 nov. 2025.

BORYS, J. **Plugin reloader**. 2025. Disponível em: https://plugins.qgis.org/plugins/plugin_reloader/. Acesso em: 26 out. 2025.

CHEN, Q. *et al.* Spectral indices in remote sensing of soil: definition, popularity, and issues. a critical overview. **Remote Sensing of Environment**, v. 329, 2025. DOI: 10.1016/j.rse.2025.114918. Disponível em: linkinghub.elsevier.com/retrieve/pii/S0034425725003220. Acesso em: 11 nov. 2025.

ESQUERDO, J. C. D. *et al.* SATVeg: a web-based tool for visualization of MODIS vegetation indices in South America. **Computers and Electronics in Agriculture**, v. 175, 2020.

EUROPEAN SPACE AGENCY. **Overview of sentinel-2 mission**. 2025. Disponível em: <https://sentiwiki.copernicus.eu/web/s2-mission>. Acesso em: 26 out. 2025.

FREITAS, R. G. *et al.* Predicting on-farm soybean yield variability using texture measures on Sentinel-2 image. **Precision Agriculture**, v. 25, n. 6, p. 2977-3000, 2024. DOI: 10.1007/s11119-024-10176-3. Disponível em <https://link.springer.com/article/10.1007/s11119-024-10176-3>. Acesso em: 26 out. 2025.

GASTAUER, M. *et al.* Sensoriamento remoto orbital. *In: Protocolo de monitoramento da restauração da Mata Atlântica e da Amazônia via sensoriamento remoto*. Brasília: The Nature Conservancy do Brasil, 2024. p. 74–88.

GEE COMMUNITY. **Google earth engine plugin for QGIS**. 2025. Disponível em: <https://gee-community.github.io/qgis-earthengine-plugin/>. Acesso em: 24 out. 2025.

GEOAPT LLC. **Plugin builder 3**. Versão 2.18.0. Disponível em: <https://plugins.qgis.org/plugins/pluginbuilder/version/2.18.0/>. Acesso em: 26 out. 2025.

GÓMEZ, C.; ALEJANDRO, P.; MONTES, F. Phenological characterization of *Fagus sylvatica* L. in Mediterranean populations of the Spanish Central Range with Landsat OLI/ETM+ and Sentinel-2A/B. **Revista de Teledetección**, v. 2020, 2020.

GOOGLE. **Apps do earth engine**. Google for developers. 2025. Disponível em: <https://developers.google.com/earth-engine/guides/apps?hl=pt-br>. Acesso em: 13 dez. 2025.

GOOGLE CLOUD. **Criar e gerenciar projetos**. 2025. Disponível em: <https://docs.cloud.google.com/resource-manager/docs/creating-managing-projects?hl=pt-br>. Acesso em: 26 out. 2025.

GOOGLE EARTH ENGINE. **A planetary-scale platform for earth science data & analysis**. 2025. Disponível em: <https://earthengine.google.com/>. Acesso em: 24 out. 2025.

GORELICK, N. *et al.* Google earth engine: planetary-scale geospatial analysis for everyone. **Remote Sensing of Environment**, v. 202, p. 18-27, 2017.

HUETE, A.; JUSTICE, C.; LIU, H. Development of vegetation and soil indices for MODIS-EOS. **Remote Sensing of Environment**, v. 49, n. 3, p. 224-234, 1994.

JAVED, A. Review of spectral indices for urban remote sensing. **Photogrammetric Engineering & Remote Sensing**, v. 87, n. 7, p. 513-524, 2021. DOI: 10.14358/PERS.87.7.513. Disponível em: <https://www.ingentaconnect.com/content/asprs/pers/2021/00000087/00000007/art00013;jsessionid=7ler951l5lit3.x-ic-live-02>. Acesso em: 11 nov. 2025.

JENSEN, J. R. **Sensoriamento remoto do ambiente**: uma perspectiva em recursos terrestres. 2. ed. São José dos Campos: Parêntese, 2009.

JURGIEL, B. **Plugin reloader**. Versão 0.18; QGIS, 2025. Disponível em: https://plugins.qgis.org/plugins/plugin_reloader/. Acesso em: 26 out. 2025.

LANG, S.; BLASCHKE, T. **Análise da paisagem com SIG**. São Paulo: Oficina de Textos, 2009.

LIAGHAT, S.; BALASUNDRAM, S. K. A review: The role of remote sensing in

precision agriculture. **American Journal of Agricultural and Biological Sciences**, v. 5, n. 1, p. 50-55, 2010.

MCFADDEN, J.; NJUKI, E.; GRIFFIN, T. **Precision agriculture in the digital era: recent adoption on U.S. farms**. Washington: Department of Agriculture, Economic Research Service, 2023. Disponível em: <https://ageconsearch.umn.edu/record/333550/?v=pdf>. Acesso em: 25 out. 2025.

MELO, D. D.; CUNHA, I. A.; AMARAL, L. R. Hierarchical stratification for spatial sampling and digital mapping of soil attributes. **AgriEngineering**, v. 7, n. 1, p. 10, 2025.

MELL, P.; GRANCE, T. **The NIST definition of cloud computing**. Gaithersburg: National Institute of Standards and Technology, 2011. Disponível em: <https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-145.pdf>. Acesso em: 21 nov. 2025.

MENESES, P. R.; ALMEIDA, T. **Processamento de imagens de sensoriamento remoto**. Brasília: Editora Universidade de Brasília, 2025.

MGENDI, G. Unlocking the potential of precision agriculture for sustainable farming. **Discover Agriculture**, v. 2, n. 1, 2024.

MOLIN, J. P. **Boletim Técnico 03 - agricultura de precisão: números do mercado brasileiro**. Piracicaba/SP: Laboratório de Agricultura de Precisão - LAP/ESALQ/USP. 2017. Disponível em: <https://www.agriculturadeprecisao.org.br/boletim-tecnico-03-agricultura-de-precisao-numeros-do-mercado-brasileiro>. Acesso em: 19 nov. 2025.

NOVO, E. M. L. M. **Sensoriamento remoto: princípios e aplicações**. 4. ed. São Paulo: Blücher, 2010.

PEREIRA, G. W. *et al.* Smart-map: an open-source QGIS plugin for digital mapping using machine learning techniques and ordinary kriging. **Agronomy**, v. 12, n. 6, p. 1350, 2022.

PERICH, G. *et al.* Pixel-based yield mapping and prediction from Sentinel-2 using spectral indices and neural networks. **Field Crops Research**, v. 292, 2023. DOI: 10.1016/j.fcr.2023.108824. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0378429023000175?via%3Dihub>. Acesso em: 21 nov. 2025.

QGIS DEVELOPMENT TEAM. **QGIS geographic information system**. 2025. Disponível em: <https://qgis.org>. Acesso em: 21 nov. 2025.

QIU, S. *et al.* Evaluation of landsat image compositing algorithms. **Remote Sensing of Environment**, v. 285, 2023.

ROUSE, J. W. *et al.* **Monitoring the vernal advancement and retrogradation (greenwave effect) of natural vegetation**. Greenbelt: NASA/GSFC, 1973.

THE QT COMPANY. **Qt designer**. Versão 6.8. [Finlândia]: The Qt Company, 2025. Disponível em: <https://www.qt.io/product/ui-design-tools>. Acesso em: 21 nov. 2025.

RADOČAJ, D. State of major vegetation indices in precision agriculture studies indexed in Web of Science: a review. **Agriculture**, v. 13, n. 3, p. 707, 2023.

RATCLIFF, C.; GOBBETT, D.; BRAMLEY, R. **PAT – Precision agriculture tools**. v. 3. [Software], 2020. Disponível em: <https://doi.org/10.25919/5f72d61b0bca9>. Acesso em: 24 out. 2025.

SAVITZKY, A.; GOLAY, M. J. E. Smoothing and differentiation of data by simplified least squares procedures. **Analytical Chemistry**, v. 36, n. 8, p. 1627-1639, 1964.

SEGARRA, J. *et al.* Remote sensing for precision agriculture: sentinel-2 improved features and applications. **Agronomy**, v. 10, 2020. DOI: 10.3390/agronomy10050641. Disponível em: <https://www.mdpi.com/2073-4395/10/5/641>. Acesso em: 11 nov. 2025.

SEGARRA, J. Satellite imagery in precision agriculture. *In*: SASTRY, J. K. R.; VILLIERS, C.; BALAS, V. E. (ed.). **Precision agriculture: evolution, insights and emerging trends**. Cham: Springer, 2024. p. 325-340. DOI:10.1007/978-3-031-43548-510. Disponível em https://link.springer.com/chapter/10.1007/978-3-031-43548-5_10. Acesso em: 11 nov. 2025.

SENTINEL HUB. Sentinel-2 L2A scene classification map. *In*: **Sentinel Hub**. Custom Scripts. Ljubljana: Sinergise, 2025. Disponível em: <https://custom-scripts.sentinel-hub.com/custom-scripts/sentinel-2/scene-classification>. Acesso em: 10 nov. 2025.

SENTINEL ONLINE. **Copernicus sentinel-2 (processed by ESA) MSI Level-2A BOA reflectance product collection 1**. 2021. Disponível em: <https://sentinels.copernicus.eu/web/sentinel/sentinel-data-access/sentinel-products/sentinel-2-data-products/collection-1-level-2a>. Acesso em: 11 nov. 2025.

SILVA, W. V. R.; SILVA-MANN, R. Agricultura de precisão no Brasil: conjuntura atual, desafios e perspectivas. **Pesquisa, Sociedade e Desenvolvimento**, v. 9, n. 11, 2020.

SILVERO, N. E. Q. *et al.* Soil variability and quantification based on sentinel-2 and Landsat-8 bare soil images: a comparison. **Remote Sensing of Environment**, v. 252, p. 112117, 2021. DOI: 10.1016/j.rse.2020.112117. Disponível em: <https://doi.org/10.1016/j.rse.2020.112117>. Acesso em: 13 dez. 2025.

SOMMERVILLE, I.; SAWYER, P. **Requirements engineering: a good practice guide**. Chichester: John Wiley & Sons, 1997.

SOOD, K. *et al.* **Application of GIS in precision agriculture**. 2015. Disponível em: https://www.researchgate.net/publication/295858552_Application_of_GIS_in_precision_agriculture. Acesso em: 11 nov. 2025.

SOUZA FILHO, C. R. *et al.* Detecção de exsudações de hidrocarbonetos por

geobotânica e sensoriamento remoto multi-temporal: estudo de caso no Remanso do Fogo (MG). **Revista Brasileira de Geociências**, v. 38, n. 2, p. 228-243, 2008.

VINCINI, M.; CALEGARI, F.; CASA, R. Sensitivity of leaf chlorophyll empirical estimators obtained at sentinel-2 spectral resolution for different canopy structures. **Precision Agric**, v. 17, p. 313–331, 2016. DOI: 10.1007/s11119-015-9424-7. Disponível em <https://link.springer.com/article/10.1007/s11119-015-9424-7>. Acesso em: 21 nov. 2025.

WARDLOW, B. D.; EGBERT, S. L.; KASTENS, J. H. Analysis of time-series MODIS 250 m vegetation index data for crop classification in the U.S. Central Great Plains. **Remote Sensing of Environment**, v. 108, n. 3, p. 290-310, 2007.

ZHOU, Y. *et al.* Open surface water mapping algorithms: a comparison of water-related spectral indices and sensors. **Water**, v. 9, n. 4, 2017. DOI: 10.3390/w9040256. Disponível em: <https://www.mdpi.com/2073-4441/9/4/256>. Acesso em: 11 nov. 2025.